

ChemiAI

Предсказание активности соединений против вируса гриппа

25.05.2026 Команда 5_ИИшница

Задача

ChemiAI — решение задачи хемоинформатики: по числовым молекулярным дескрипторам предсказать три показателя активности соединений **против вируса гриппа**.

Разработка лекарств требует одновременно оценить, насколько молекула **подавляет вирус** и насколько она **токсична для клеток**. Модель помогает ранжировать кандидаты до дорогих экспериментов in vitro.



Данные и ограничения

Объёмы:

- обучающая выборка — **751** молекула с известными IC50, CC50, SI;
- тест — **250** молекул без таргетов;
- признаки — **192** числовых RDKit-дескриптора (из 214; 18 константных колонок удалены).

Вход модели — не SMILES, а уже посчитанные дескрипторы: молекулярный вес, logP, топологические индексы, поверхностные VSA, бинарные функциональные группы (fr_*) и др.

Внешние данные ChEMBL — база похожих активных молекул:

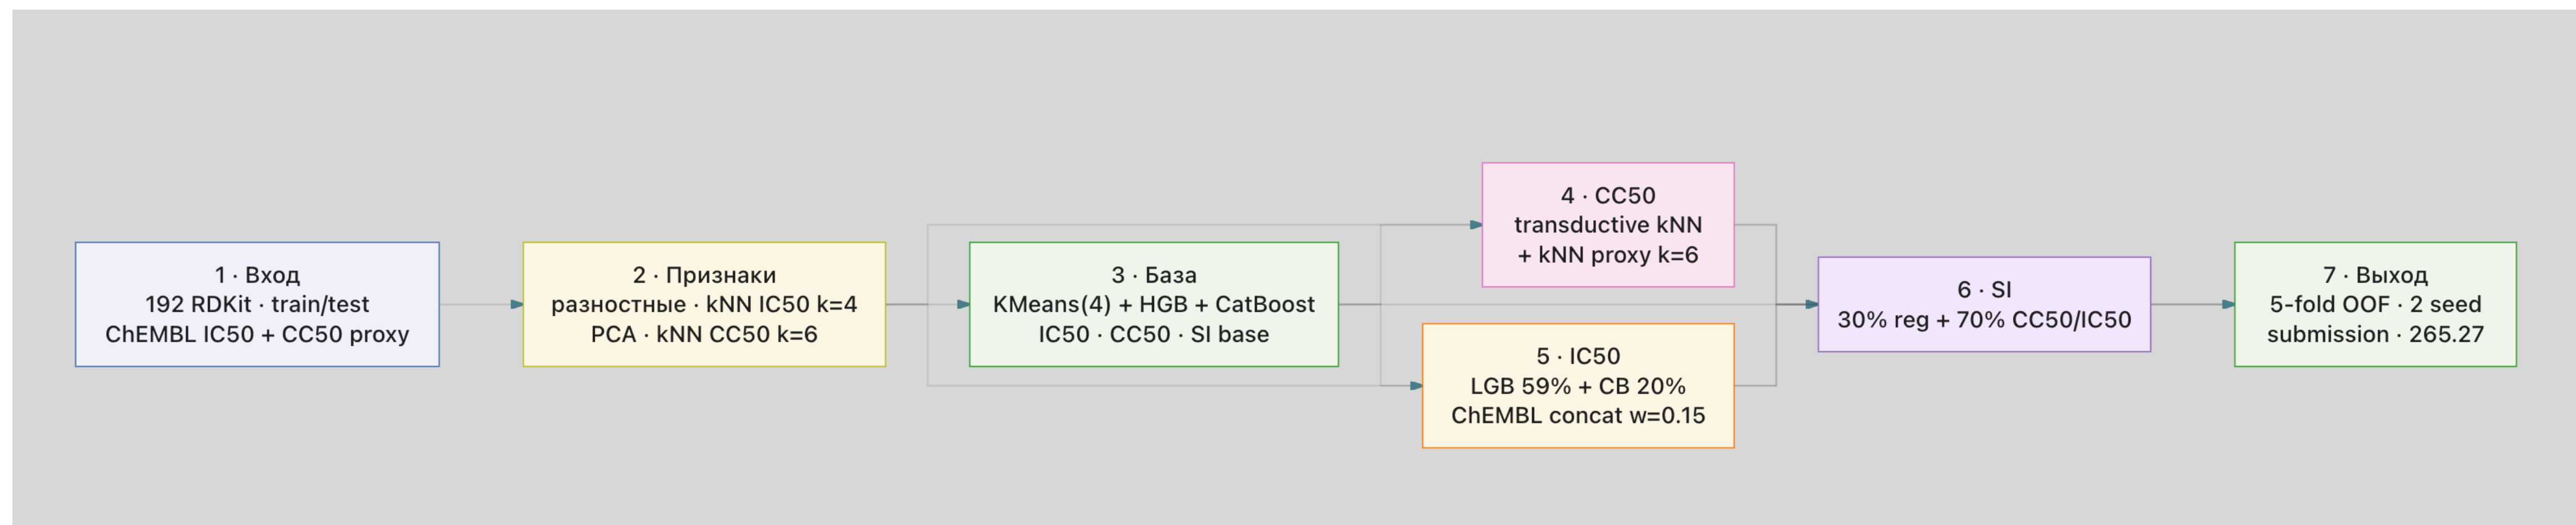
- IC50 для kNN-признаков и дообучения LightGBM;
- прокси CC50 для kNN по токсичности.

Идея решения

- Не одна модель, а **ансамбль с отдельной логикой** для каждого таргета
- Базовый блок — **KMeans + HGB + CatBoost** для всех трёх
- Специализированные ветки IC50 / CC50 / SI
- **ChEMBL** — внешние похожие молекулы, с малым весом
- **35+** фаз итераций: **~306 → 265.27 RMSE**



Общая схема пайплайна




Общая схема (1→7) — сводный вид пайплайна BEST_CFG: линейная цепочка «вход → признаки → базовый ансамбль», затем три параллельные ветки таргетов и общий выход.

Блок 3 — развилка — из одного базового ансамбля (KMeans + HGB + CatBoost) получаем три base-сигнала; ветки **4 (CC50)** и **5 (IC50)** дополняются признаками из §2 (kNN, PCA, разностные).

Блок 6 — сборка SI — финальный SI смешивает регрессию (30%) с отношением **CC50/IC50** (70%); для ratio нужны уже предсказанные CC50 и IC50 из веток 4–5 (стрелки S4→S6, S5→S6).

Блок 7 — 5-fold OOF на train, усреднение двух seed (42, 7) на test → `submission.csv`, RMSE **265.27**. Подробности каждого шага — на слайдах 1–7.

Входные данные




ChEMBL (Chemical Database of Bioactive Molecules) — открытая база биоактивных соединений с экспериментальными данными об активности против мишеней.

В проекте используем **отфильтрованную подвыборку** молекул, структурно похожих на наши (sim-filter, «potent lib»): IC50 — для kNN-признаков и дообучения LightGBM, прокси CC50 — для kNN по токсичности.

Дескрипторы ChEMBL выровнены с train; внешние строки добавляются с **малым весом (0.15)**, чтобы не сместить модель на чужое распределение.

Инженерия признаков




Разностные признаки (fe) — вычисленные признаки: разности между группами дескрипторов (гетероциклы vs гибкость и размер молекулы).

kNN cal (калибр.) — медиана таргета у k ближайших соседей из ChEMBL; шкала приведена к train (quantile mapping).

kNN raw (сырой) — та же медиана соседей без калибровки шкалы; для IC50 используем оба варианта (dual).

PCA train + test — трансдуктивный PCA на объединении выборок; учитывает структуру test-молекул (ветка CC50).

Базовый ансамбль — IC50, CC50, SI




192 RDKit-дескриптора — impute + scale; на каждом CV-фолде KMeans делит молекулы на **4 кластера** (по всем признакам сразу).

HGB + CatBoost — две регрессии на признаках «дескрипторы + one-hot кластера»; отдельная модель для **IC50**, **CC50** и **SI**. Предсказания моделей усредняются.

IC50 / CC50 / SI base — базовый сигнал для специализированных веток (4–6). Кластеры — data-driven сегменты, не фиксированные химические классы.


Ветка CC50 — токсичность для клеток



CC50 proxy (прокси) — не измеренная токсичность из ChEMBL, а **косвенная оценка**. В базе похожих молекул есть **IC50**, но нет реального **CC50** для нашей клеточной линии. Proxy строится так: IC50 молекулы ChEMBL → **quantile mapping** по связи IC50↔CC50 на train → синтетический CC50_mM.

kNN ChEMBL proxy · k=6 — медиана proxy-CC50 у 6 ближайших соседей по дескрипторам; шкала калибруется на train (как в §2). Это **признак для модели**, а не прямое измерение токсичности.


Ветка IC50 — подавление вируса



Признаки **разностные** и **kNN IC50** — те же, что в 2; здесь они входят в LightGBM и CatBoost.

ChEMBL concat — в каждом фолде к нашим train-строкам **добавляются** молекулы ChEMBL с IC50 (те же признаки). Внешние строки учитываются с весом **0.15**, наши — **1.0**. Только для **LightGBM**, чтобы ChEMBL не «перетянул» модель.

Ветка SI — индекс селективности




SI base • регрессия — предсказание SI из базового ансамбля (3): модель учится предсказывать SI как отдельный таргет по RDKit-признакам.

CC50 / IC50 (ratio) — отношение **уже предсказанных** CC50 и IC50 (4–5); химический смысл: селективность $\approx$ токсичность / активность.

30% модель + 70% ratio — финальная формула: $SI = 0.30 \cdot SI_{pred} + 0.70 \cdot CC50/IC50$ (параметр $\alpha = 0.30$). Мягкий компромисс: не жёсткая формула и не чистая регрессия.

Валидация и выход



5-fold CV · OOF — train делится на 5 частей; каждый объект один раз в validation. Получаем OOF-предсказания и локальную метрику на train ($\approx$ **525 RMSE**). Трансдуктивные признаки **завышают** OOF относительно test.

2 seed · 42 и 7 — полный пайплайн запускается дважды с разным random_state; предсказания для test **усредняются**. 3–5 seed проверяли — хуже best (**265.80**).

submission.csv — итоговый файл: index, IC50, CC50, SI. Лучший RMSE на test: **265.27**.

Выводы

1. **Три таргета — три ветки** лучше, чем одна модель на всё сразу
2. **ChEMBL** помогает, но только **похожие** молекулы и **малый вес 0.15**
3. **kNN-соседи + разностные признаки** — последний заметный прирост качества
4. **SI** считаем как смесь модели (30%) и формулы CC50/IC50 (70%), без meta-моделей
5. **Усреднение 2 seed** — простой и достаточный способ стабилизировать test